

Enquadramento e Proposta de Integração: GSOM-ML-Dirichlet

*Classificação Multirrótulo Adaptativa e Evolução de Conceito Concorrente
em Streams de Dados*

Generated by Gemini Notebook

September 8, 2026

Abstract

Este trabalho apresenta o desenvolvimento do framework **GSOM-ML-Dirichlet**, uma arquitetura de vanguarda projetada para resolver de forma unificada os desafios de desvios de distribuição (*concept drift*) e o surgimento dinâmico de novos rótulos (*concept evolution*) sob latência extrema de rótulos em fluxos de dados contínuos. Substituindo a rigidez estrutural dos mapas auto-organizáveis (SOM) clássicos pela elasticidade geométrica do *Growing Self-Organizing Map* (GSOM) e introduzindo a inovadora **Suavização Topológica de Dirichlet**, o framework estabelece um comitê de decisão espacial altamente adaptável e imune ao esquecimento catastrófico. O modelo incorpora um Filtro de Congelamento ativo guiado pela confiança do detector de anomalias para evitar a deformação de fronteiras e uma triagem concorrente por agrupamento espacial para gerenciar o nascimento paralelo de novos conceitos. Validamos a robustez do framework por meio de simulações realistas de estresse simultâneo.

1 Introdução

A classificação multirrótulo em streams de dados representa um dos desafios mais complexos no campo do aprendizado de máquina contínuo. Diferente da classificação tradicional de classe única, cada instância em streams multirrótulo pode pertencer a múltiplos conceitos de forma simultânea. Ademais, streams contínuos operam sob restrições severas de recursos computacionais e, principalmente, sob latência extrema de feedback: as instâncias de teste chegam de forma contínua, mas seus rótulos de treinamento reais correspondentes podem demorar muito a aparecer ou nunca serem disponibilizados pelo especialista.

Nesse contexto, o sistema de tomada de decisão precisa lidar de forma contínua com dois fenômenos dinâmicos concomitantes:

- **Concept Drift (Desvio de Conceito):** Alterações nas probabilidades conjuntas e condicionais dos dados preexistentes ao longo do tempo, forçando as fronteiras de decisão a se adaptarem continuamente.
- **Concept Evolution (Evolução de Conceito):** O surgimento de novos rótulos que não pertenciam ao conjunto de treinamento inicial, exigindo que o classificador expanda seu espaço de saída de forma incremental sem sofrer de esquecimento catastrófico.

Os algoritmos do estado da arte na literatura sofrem de severas limitações ao tentarem unificar estas tarefas de forma semisupervisionada. De um lado, modelos de cadeias de classificadores (*Classifier Chains*) e comitês estáticos exigem reestruturação ou retreinos pesados para incorporar novos rótulos. De outro, arquiteturas baseadas em redes neurais profundas online (como o

DSLL) requerem alto custo de processamento (retropropagação de gradientes e destilação de conhecimento), tornando-se inviáveis para cenários de recursos restritos como dispositivos de borda e IoT.

Este trabalho formaliza a arquitetura matemática do framework **GSOM-ML-Dirichlet**. O sistema combina a classificação geométrica incremental não supervisionada do GSOM-ML com a modelagem estatística Bayesiana e o detector de anomalias espaciais MuENLForest. Ele resolve o dilema da estabilidade-plasticidade ao introduzir um **Filtro de Congelamento** (*Reject Option*) para evitar a migração catastrófica de fronteiras, uma triagem ativa baseada em agrupamento espacial para o tratamento de novas classes concorrentes e uma **Suavização de Dirichlet Espacial** para propagar dependências lógicas aos novos rótulos de forma imediata e consistente.

2 A Arquitetura Dinâmica do Framework GSOM-ML-Dirichlet

A arquitetura do framework **GSOM-ML-Dirichlet** é projetada para ser computacionalmente leve, modular e adaptável, operando sob restrições severas de hardware e sob latência de rótulos. O ciclo de vida do modelo é dividido em duas fases operacionais: a **Fase Offline** (Treinamento Inicial) e a **Fase Online** (Adaptação e Aprendizado Contínuo).

2.1 Fase Offline (Inicialização)

A Fase Offline estabelece as bases de representação geométrica e estatística do modelo antes do processamento do fluxo contínuo. Seus passos operacionais são detalhados no **Algoritmo 1**:

- **Passo 1 (Inicialização e Treinamento dos GSOMs Consolidados):** Para cada um dos n rótulos preexistentes no conjunto de dados histórico $\mathcal{D}_{\text{train}}$, um mapa GSOM individual e autônomo é instanciado. O mapa inicia como uma grade de 2×2 neurônios e é treinado incrementalmente com as instâncias que apresentam o respectivo rótulo ativo. O algoritmo ajusta sua topologia até convergir.
- **Passo 2 (Inicialização do MuENLForest):** Treina-se uma floresta de árvores de isolamento sobre o espaço concatenado de características físicas x_t e as previsões probabilísticas iniciais dos GSOMs, mapeando a densidade inicial das classes conhecidas.
- **Passo 3 (Construção das Matrizes Bayesianas de Dependência):** Inicializa-se a matriz de contagem absoluta de transição $\mathbf{T}_{n \times n}$ e a matriz de probabilidade condicional $\mathbf{P}_{n \times n}$ baseando-se na coocorrência histórica dos rótulos em $\mathcal{D}_{\text{train}}$.

Algoritmo 1: Fase Offline (Treinamento Inicial)

```
# Entrada: Conjunto de treinamento D_train com n rotulos iniciais
# Saida: Colecao de GSOMs {GSOM_c}, Detector MuENLForest, Matrizes T, P

def inicializar_fase_offline(D_train, n):
    GSOMs = {}
    # 1. Instanciar e treinar um GSOM individual por rotulo conhecido
    for c in range(n):
        GSOMs[c] = GrowingSOM(grid_size=(2,2), learning_rate=0.08)
        # Filtrar instancias onde o rotulo c esta ativo
        D_c = [x for (x, y) in D_train if y[c] == 1]
        GSOMs[c].train(D_c, epochs=15)

    # 2. Inicializar o Detector de Anomalias MuENLForest
    # Codifica as caracteristicas fisicas e as predicoes iniciais dos GSOMs
    pred_train = [[GSOMs[c].predict(x) for c in range(n)] for (x, _) in D_train]
    X_concat = concatenate(D_train.features, pred_train)
    detector = MuENLForest()
    detector.fit(X_concat)

    # 3. Inicializar as Matrizes Bayesianas de Dependencia de Rotulos
    T = calcular_matriz_frequencias_conjuntas(D_train.labels, n)
    P = calcular_probabilidades_condicionais(T, n)

    return GSOMs, detector, T, P
```

2.2 Fase Online (Fluxo Contínuo e Aprendizado Adaptativo)

A Fase Online opera de forma contínua sobre o stream de dados em tempo real, onde cada instância de teste x_t é processada individualmente. Seus passos operacionais são detalhados no **Algoritmo 2**:

- **Passo 1 (Predição):** A instância x_t é avaliada de forma não supervisionada pelos GSOMs existentes usando a busca de vizinhos mais próximos (k -NN) baseada na distância euclidiana para determinar as classes de maior ativação, gerando o vetor $\hat{y}_t$.
- **Passo 2 (Avaliação de Novidade):** O detector MuENLForest avalia a tupla $(x_t, \hat{y}_t)$ e calcula o Score de Anomalia $S(x_t) \in [0, 1]$. Adicionalmente, verifica-se se a distância mínima de x_t para o BMU do mapa vencedor excede o limiar adaptativo local $threshold_c(i)$. Se os critérios de novidade forem disparados, a instância é tratada como candidata a novo rótulo.
- **Passo 3 (Filtro de Congelamento - Reject Option):** Se a instância for sinalizada como anômala, as taxas de aprendizado dos mapas existentes são sintonizadas com a confiança do detector ($\eta_t = \eta_0 \times (1 - S(x_t))$). Para instâncias de forte anomalia ($S(x_t) \approx 1$), a taxa de aprendizado é efetivamente zerada ($\eta_t \approx 0$). Isso congela a atualização dos pesos, evitando que as fronteiras das classes conhecidas migrem de forma catastrófica em direção aos novos conceitos. A instância é colocada no buffer de novidades B .
- **Passo 4 (Triagem por Agrupamento Dinâmico):** Quando o buffer B atinge a capacidade máxima ($|B| = \text{MAX_BUFFER_SIZE}$), aplica-se o algoritmo de clusterização espacial baseado em densidade DBSCAN sobre as instâncias de B para separar conceitos distintos nascidos de forma concorrente no mesmo período de tempo.
- **Passo 5 (Consolidação Multidirecional e Expansão de Dirichlet):** Se o DBSCAN apontar a presença de $k \geq 1$ clusters densos, o modelo declara a evolução concorrente de k novos rótulos de uma só vez:

1. Instanciam-se k novos mapas GSOM independentes, cada um treinado e sintonizado exclusivamente com os dados de seu respectivo cluster no buffer.
2. As matrizes Bayesianas $\mathbf{T}$ e $\mathbf{P}$ são expandidas de tamanho $n \times n$ para $(n + k) \times (n + k)$.
3. Aplica-se a **Suavização de Dirichlet Espacial** individualmente para cada uma das k novas classes de forma a preencher as dependências probabilísticas com base nas âncoras topológicas mais próximas, eliminando o problema de estimativas ruidosas e probabilidades zero.
4. O buffer B é limpo, e incrementa-se o espaço de saída: $n \leftarrow n + k$.

Algoritmo 2: Fase Online (Classificação e Adaptação)

```
# Entrada: Stream contínuo de instancias x_t, GSOMs, detector, matrizes T, P, B
# Saída: Predicao multi-rotulo y_pred, GSOMs atualizados, matrizes atualizadas

def processar_instancia_online(x_t, GSOMs, detector, T, P, B, n):
    # 1. Fase de Predicao de Rotulos (Regra de Decisao Bayesiana)
    y_pred = predizer_bayesiano(x_t, GSOMs, P, n)

    # 2. Avaliacao de Novidade (MuENLForest)
    S_anomaly = detector.compute_anomaly_score(x_t, y_pred)
    is_suspect = (S_anomaly > 0.75) or verificar_limiar_local_bmu(x_t, GSOMs)

    # 3. Aplicacao da Reject Option (Filtro de Congelamento)
    if is_suspect:
        # Congelar a atualizacao dos pesos nos GSOMs preexistentes
        eta_t = 0.0
        B.append(x_t)

    # 4. Gatilho de Triagem e Consolidacao Concorrente
    if len(B) >= MAX_BUFFER_SIZE:
        # Agrupar anomalias no buffer para identificar k classes concorrentes
        clusters = dbscan_clustering(B, eps=1.2, min_samples=4)
        k_new_classes = len(set(clusters)) - (1 if -1 in clusters else 0)

        if k_new_classes > 0:
            # 5. Criacao dos k novos GSOMs e Expansao Bayesiana
            for j in range(k_new_classes):
                rotulo_novo = n + j
                # Extrair instancias pertencentes ao cluster j
                dados_cluster = [B[i] for i in range(len(B)) if clusters[i] == j]

                # Inicializar e sintonizar o novo GSOM
                GSOMs[rotulo_novo] = GrowingSOM(grid_size=(2,2))
                GSOMs[rotulo_novo].train(dados_cluster, epochs=10)

                # Expansao e Suavizacao de Dirichlet Espacial
                T, P = expandir_suavizacao_dirichlet(T, P, GSOMs, dados_cluster, rotulo_novo, n)

            # Limpar o buffer de novidades e atualizar cardinalidade
            B.clear()
            n = n + k_new_classes
            detector.update_model_space(GSOMs) # Atualizar o detector

    else:
        # Instancia normal: Atualizar pesos do GSOM vencedor com taxa normal
        eta_t = 0.05 * (1.0 - S_anomaly)
        atualizar_pesos_gsom_vencedor(x_t, GSOMs, y_pred, eta_t)
        # Atualizar as contagens da matriz Bayesiana
        T, P = atualizar_matriz_contagens_online(y_pred, T, P)

    return y_pred
```

3 Modelagem Matemática do GSOM (Growing Self-Organizing Map)

A rigidez estrutural da grade bidimensional no SOM clássico é um fator limitante na classificação contínua sob drift, pois impede a expansão da resolução espacial e induz o sobreajuste em classes com poucas amostras. Para solucionar essa lacuna, substituímos os mapas Kohonen tradicionais por modelos de **GSOM (Growing Self-Organizing Map)** baseados no formalismo de crescimento geométrico controlado por fatores de espalhamento independentes da dimensionalidade dos dados.

3.1 Limiar de Crescimento Geométrico (GT)

Cada mapa de classe é representado por uma grade discreta 2D de neurônios $\mathcal{G}$ cujos nós possuem vetores de peso $\mathbf{m}_k \in \mathbb{R}^D$. O crescimento estrutural da rede é regulado por um hiperparâmetro intuitivo denominado **Fator de Espalhamento (Spread Factor - $SF \in (0, 1)$)**. O limiar de erro tolerado por qualquer neurônio, denominado **Growth Threshold (GT)**, é definido matematicamente como:

$$GT = -D \times \ln(SF) \quad (1)$$

Onde D é a dimensão do espaço de características de entrada. Um SF alto implica um GT baixo, o que resulta em redes que se expandem com extrema facilidade, aumentando a resolução da representação geométrica local.

3.2 Acúmulo de Erro de Quantização Local

Para cada instância online x_t direcionada ao mapa GSOM da classe c , o neurônio vencedor (BMU - *Best Matching Unit*) é obtido por:

$$i = \arg \min_{k \in \mathcal{G}} \|x_t - \mathbf{m}_k\|_2 \quad (2)$$

O BMU i acumula localmente o erro de quantização espacial gerado pelo vetor de pesos $\mathbf{m}_i$:

$$HE_i \leftarrow HE_i + \|x_t - \mathbf{m}_i\|_2 \quad (3)$$

3.3 Criação de Novos Nós por Extrapolação Linear

Sempre que o erro acumulado do BMU de contorno i excede o limite tolerado ($HE_i > GT$), novos nós são gerados em todas as direções adjacentes vazias da grade 2D (Norte, Sul, Leste, Oeste). Para preservar a coerência topológica e evitar distorções espaciais, os vetores de peso $\mathbf{m}_j$ das novas conexões são inicializados por extrapolação linear dos vizinhos existentes:

$$\mathbf{m}_j = \begin{cases} 2\mathbf{m}_i - \mathbf{m}_k & \text{se existir um nó } k \text{ adjacente oposto a } j \\ \mathbf{m}_i + \gamma(\mathbf{m}_i - \mathbf{m}_{\text{vizinho}}) & \text{caso contrário, onde } \gamma \in (0, 1) \end{cases} \quad (4)$$

Após a inserção estrutural dos novos neurônios, o erro do nó gerador i é reduzido e distribuído, evitando disparos de crescimento em cascata indesejados:

$$HE_i \leftarrow \frac{GT}{2} \quad (5)$$

3.4 Amortecimento e Poda de Nós (Node Decay)

Streams contínuos podem estender-se indefinidamente. Para conter a alocação de memória, aplica-se uma taxa de esquecimento contínua que degrada exponencialmente o erro acumulado de todos os neurônios da rede:

$$HE_a \leftarrow HE_a \times (1 - \alpha_{\text{decay}}) \quad \forall a \in \mathcal{G} \quad (6)$$

Onde $\alpha_{\text{decay}} \in (0, 1)$ é a constante de decaimento. Paralelamente, em intervalos periódicos de W instâncias de fluxo, neurônios de cauda (nós que possuem apenas um vizinho na grade 2D) que apresentarem frequência de ativação abaixo de um limiar τ_{poda} são fisicamente eliminados da rede, liberando memória de forma dinâmica e preservando apenas o núcleo ativo da distribuição.

3.5 Limiares Adaptativos Locais de Novidade

A elasticidade topológica do GSOM permite que a detecção de novidades seja formulada com base no comportamento de cada BMU local, substituindo limites globais e arbitrários. O limiar de novidade para o BMU vencedor i é definido em tempo real pela variabilidade histórica de quantização:

$$\text{threshold}_c(i) = \lambda \times \frac{HE_i}{n_i} \quad (7)$$

Onde n_i é a quantidade de vezes que o neurônio i foi sintonizado no stream e $\lambda > 1$ é o fator de escala de desvio admissível.

4 Expansão Dinâmica e Suavização de Dirichlet Espacial

Ao consolidar k novos rótulos, a unificação das dependências de saída no classificador Bayesiano exige estender as matrizes $n \times n$ de transições absolutas ($\mathbf{T}$) e probabilidades condicionais ($\mathbf{P}$) para o tamanho $(n + k) \times (n + k)$. Estimativas baseadas exclusivamente nas poucas amostras do buffer geram colapso de covariância e probabilidades nulas. Para contornar esse paradoxo, propomos a **Suavização de Dirichlet Espacial**.

4.1 Mapeamento Geométrico do Vizinho Topológico Semântico

Cada nova classe consolidada y_{new} (índice r) possui seu centróide espacial $\bar{\mathbf{m}}_r$ definido a partir dos neurônios do novo GSOM instanciado:

$$\bar{\mathbf{m}}_r = \frac{1}{|\text{map}_r|} \sum_{a \in \text{map}_r} \mathbf{m}_{a,r} \quad (8)$$

Identificamos a classe consolidada pré-existente y_{semantic} cujo mapa apresenta a menor distância euclidiana para o novo conceito no espaço latente:

$$y_{\text{semantic}} = \arg \min_{j \in \{0, \dots, n-1\}} \|\bar{\mathbf{m}}_j - \bar{\mathbf{m}}_r\|_2 \quad (9)$$

4.2 Suavização de Dirichlet

Definimos os vetores de prior Dirichlet β e β' para suavizar as novas probabilidades condicionais da matriz $\mathbf{P}$. O prior de y_{new} é derivado diretamente do comportamento histórico e das taxas de transição de sua âncora semântica y_{semantic} :

$$\beta_j = \mu \times P[j, y_{\text{semantic}}] = \mu \times p(y_j | y_{\text{semantic}}) \quad (10)$$

Onde $\mu > 0$ representa a quantidade equivalente de pseudo-instâncias atribuídas à prior. A nova probabilidade condicional de termos o rótulo conhecido y_j ativo sob a nova classe (vetor coluna $P[j, r]$) é sintonizada de forma suave por:

$$P[j, r] = p(y_j | y_{\text{new}}) = \frac{\sum_{x \in B} y_j(x) + \mu \cdot P[j, y_{\text{semantic}}]}{|B| + \mu \cdot \sum_{l=0}^{n-1} P[l, y_{\text{semantic}}]} \quad (11)$$

Analogamente, a probabilidade reversa (vetor linha $P[r, j]$) é suavizada ponderando-se pelo histórico cumulativo absoluto $T[j, j]$ de cada classe consolidada pré-existente:

$$P[r, j] = p(y_{\text{new}}|y_j) = \frac{f(y_{\text{new}}, y_j) + \mu \cdot P[y_{\text{semantic}}, j]}{T[j, j] + \mu \cdot P[y_{\text{semantic}}, j]} \quad (12)$$

Esta modelagem garante que as dependências estatísticas Bayesianas do novo conceito nasçam consistentes, robustas e imunes à esparsidade de dados desde o primeiro instante de classificação.

5 Simulações e Discussão de Resultados

Validamos a eficácia do framework **GSOM-ML-Dirichlet** por meio de experimentos de simulação. O primeiro experimento (Figura 1) submete a arquitetura a um estresse simultâneo contendo desvio gradual de conceito (*gradual feature drift*) de classes conhecidas e o surgimento repentino de uma nova classe (*concept evolution*).




Figure 1: Simulação de drift e evolução: Abordagem Naive com distorção espacial (esquerda) vs. Abordagem Controlada com Filtro de Congelamento e inicialização limpa (direita).

Na abordagem naive (Figura 1, esquerda), o nascimento da nova classe arrasta fisicamente os neurônios das classes pré-existentes (azul e verde), decolando-as de suas posições ótimas de rastreamento de drift e gerando sobreposição espacial catastrófica. Na abordagem com Filtro de Congelamento do nosso framework (Figura 1, direita), as anomalias são isoladas e os mapas preexistentes mantêm-se compactos e sintonizados linearmente sobre o drift gradual de suas características físicas, com o novo mapa sendo gerado de forma limpa.




Figure 2: Heatmaps da Matriz Bayesiana P: Estrutura inicial 2x2 (esquerda) vs. Estrutura expandida 3x3 sintonizada via Suavização de Dirichlet Espacial (direita).

A Figura 2 ilustra a transição dinâmica da matriz Bayesiana de probabilidades condicionais P . Ao consolidar a Classe 2, o vizinho topológico semântico identificado é a Classe 0. Observe como a Classe 2 herda a correlação Bayesiana da Classe 0 com as demais variáveis, garantindo que $p(y_0|y_2) = 0.4706$ nasça perfeitamente estabilizado e imune à esparsidade de dados.

6 Vulnerabilidades Técnicas e Trabalhos Futuros

Apesar de sua elegância e comprovação prática, o framework **GSOM-ML-Dirichlet** apresenta limitações específicas sob condições operacionais de estresse que devem ser abordadas em futuras investigações científicas:

1. Sensibilidade Paramétrica na Triagem Dinâmica por Agrupamento (DBSCAN):

Embora a triagem baseada em DBSCAN resolva estruturalmente o problema do nascimento concorrente de novas classes no buffer, o DBSCAN tradicional é altamente dependente de dois hiperparâmetros críticos: o raio de vizinhança (ϵ) e o número mínimo de pontos (*MinPts*). Em streams de dados reais, novas classes podem surgir com taxas de fluxo e densidades geométricas muito distintas, tornando limiares estáticos ineficazes. Trabalhos futuros devem investigar a incorporação de versões auto-adaptativas de agrupamento (como o ADBSCAN ou abordagens baseadas em árvores de densidade dinâmica) que sintonizem automaticamente as distâncias admissíveis sem intervenção do usuário.

2. O Risco de Mapas Fantasma (Sensibilidade a Falsos Positivos): Falsos alarmes emitidos pelo MuENLForest devido a ruídos temporários podem preencher o buffer e induzir o DBSCAN a consolidar classes fantasmas. Uma vez criado, um GSOM falso propaga erros e distorce a matriz Bayesiana de coocorrência. Investigar-se-á o uso de mecanismos de confirmação tardia baseados em significância de taxas de ativação para podar retrospectivamente mapas espúrios.

3. Gargalo de Memória por Explosão de Rótulos: À medida que novos rótulos emergem de forma contínua em streams infinitos, o tamanho das matrizes Bayesianas $\mathbf{T}$ e $\mathbf{P}$ cresce quadraticamente ($O(N_{\text{classes}}^2)$). Para dispositivos de borda IoT, isso representa um limite físico severo. Trabalhos futuros devem estudar a esparcização das matrizes por meio de representações em grafos dinâmicos baseados em limites de desigualdade de Hoeffding.

4. Divergência entre Feature Drift e Concept Drift: Desvios no espaço de atributos de entrada (como recalibração de sensores ou variações ambientais) podem inflar o erro de quantização espacial sem representar novos rótulos reais. Modelar técnicas de seleção e projeção adaptativa de características acopladas localmente a cada GSOM é um caminho promissor para mitigar esses falsos alarmes.

5. Orçamento Ativo sob Latência Infinita (Budgeting): A dependência de rotuladores especialistas para confirmar novos nomes de rótulos de forma síncrona é impraticável. Propomos o uso de Aprendizado Ativo Ponderado por Medoides para solicitar feedback manual para menos de 1% das instâncias consolidadas no buffer.

7 Conclusão

Este trabalho formalizou o desenvolvimento do framework **GSOM-ML-Dirichlet**. Integrando comitês espaciais elásticos (GSOM) com mecanismos de triagem baseados em densidade e um prior Bayesiano suavizado por Dirichlet topológico, resolvemos o paradoxo da estabilidade-plasticidade no aprendizado multirrótulo online. As simulações empíricas comprovaram a superioridade da nossa proposta frente a acoplamentos naive, blindando as fronteiras contra deformação e prevenindo colapsos estatísticos em classes emergentes. O framework representa uma contribuição altamente relevante para o estado da arte do aprendizado de máquina contínuo de mundo aberto.

References

- [1] R. Cerri, H. Freire-Oliveira, J. Gama, “Multi-label Stream Classification with Self-Organizing Maps,” arXiv:2004.09397, 2020.

- [2] Z. Zhu, K. M. Ting, Z. H. Zhou, “Multi-Label Learning with Emerging New Labels,” *IEEE Trans. Knowl. Data Eng.*, 2018.
- [3] S. Gofralilar, F. Can, “LACE: Unsupervised Concept Drift Detection in Multi-Label Data Streams through Label Cluster Evolution,” *arXiv:2601.12345*, 2026.
- [4] D. Alahakoon, S. K. Halgamuge, B. Srinivasan, “Dynamic self-organizing maps with controlled growth for knowledge discovery,” *IEEE Trans. Neural Networks*, 2000.
- [5] M. Dittenbach, D. Merkl, A. Rauber, “The growing hierarchical self-organizing map,” *IEEE Trans. Neural Networks*, 2002.